

50 AÑOS
UTPL

UNIVERSIDAD TÉCNICA PARTICULAR DE LOJA

Facultad de Ingenierías y Arquitectura

Carrera de Computación

Lucas Dario Jumbo Granda

Loja

6 de mayo

2026

Estado del Arte



UTPL
La Universidad Católica de Loja

Contents

I. Resumen / Abstract	3
II. Introduccion	4
III. Marco Conceptual.....	5
IV. Trabajos Relacionados	7
V. Herramientas y Tecnologias	8
VI. Tendencias y Futuro	10
VII. Conclusiones.....	11
VIII. Referencias	12

I. Resumen / Abstract

Este documento presenta el estado del arte de la Ingeniería de Datos enfocado en la construcción de arquitecturas modernas, escalables y seguras. Se analiza la transición de los paradigmas tradicionales hacia metodologías ELT, evaluando el ecosistema de herramientas actuales (*Modern Data Stack*) que abarca el uso de lenguajes de programación, librerías de procesamiento y plataformas de orquestación de flujos de trabajo. Mediante la revisión de literatura empírica y casos de estudio en la industria y la educación superior, se destaca la importancia de la inmutabilidad, la observabilidad y el gobierno de la información. El propósito principal es establecer una base técnica y conceptual sólida que guíe el desarrollo e implementación de tuberías de datos eficientes y seguras dentro de la Dirección General de Tecnologías de la Información y Transformación Digital (DGTITD) de la Universidad Técnica Particular de Loja.

This document presents the state of the art in Data Engineering focused on building modern, scalable, and secure architectures. It analyzes the transition from traditional paradigms to ELT methodologies, evaluating the current tools ecosystem (Modern Data Stack) which includes programming languages, processing libraries, and workflow orchestration platforms. Through a review of empirical literature and case studies in industry and higher education, the importance of immutability, observability, and information governance is highlighted. The main purpose is to establish a solid technical and conceptual foundation to guide the development and implementation of efficient and secure data pipelines within the General Directorate of Information Technologies and Digital Transformation (DGTITD) of the Universidad Técnica Particular de Loja.

II. Introduccion

En la actualidad, el volumen y la velocidad con la que se genera información han transformado a los datos en el activo más crítico de cualquier organización. La Ingeniería de Datos ha evolucionado para responder a este desafío, pasando de procesos tradicionales de extracción, transformación y carga (ETL) a infraestructuras más ágiles y escalables basadas en arquitecturas Modern Data Stack, metodologías ELT (Extract, Load, Transform) y orquestación automatizada. Esta disciplina es el cimiento tecnológico que garantiza que la información cruda y dispersa se convierta en datos limpios, estructurados y seguros, listos para habilitar modelos de analítica, inteligencia artificial y visualización.

Para la **Dirección General de Tecnologías de la Información y Transformación Digital (DGTITD)** de la UTPL, la ingeniería de datos es un pilar fundamental. Al ser el área encargada de operar los sistemas, datos y automatizaciones que sostienen la gestión académica y administrativa de la universidad, es imperativo contar con *pipelines* de datos robustos, escalables y seguros. La correcta integración de múltiples fuentes institucionales mediante APIs y bases de datos centralizadas permite no solo optimizar la toma de decisiones, sino también asegurar la privacidad y gobernanza de la información universitaria.

Para comprender el panorama actual y aplicar las mejores prácticas en el desarrollo de soluciones para la DGTITD, el presente estado del arte plantea resolver las siguientes interrogantes:

1. ¿Cuáles son las herramientas y *frameworks* predominantes en la industria actual para la construcción y orquestación de flujos de datos (ETL/ELT)?
2. ¿Qué metodologías se están implementando en el sector educativo e industrial para asegurar la calidad, integridad y seguridad de los datos durante su extracción y modelado?
3. ¿Cómo se integran herramientas basadas en lenguajes como Python y SQL con plataformas de orquestación para garantizar infraestructuras de datos escalables y mantenibles en el tiempo?

III. Marco Conceptual

Para comprender el alcance y los desafíos de la Ingeniería de Datos en el desarrollo de soluciones institucionales, es indispensable definir los conceptos, arquitecturas y herramientas fundamentales que estructuran esta disciplina:

1. Ingeniería de Datos (Data Engineering)

Es la rama de la ciencia de datos enfocada en el diseño, construcción y mantenimiento de sistemas y arquitecturas que permiten la recolección, almacenamiento y procesamiento de datos a gran escala. Su objetivo principal es garantizar que los datos estén disponibles, estructurados y limpios para su posterior consumo en analítica o visualización.

2. Tuberías de Datos (Data Pipelines)

Consisten en una serie de procesos automatizados que extraen datos de diversas fuentes, los transforman al formato requerido y los cargan en un destino final de almacenamiento. Un pipeline robusto garantiza la trazabilidad y la integridad de la información durante todo su ciclo de vida.

3. Paradigmas de Procesamiento: ETL vs. ELT

ETL (Extract, Transform, Load): El modelo tradicional donde los datos son extraídos de la fuente, transformados en un servidor intermedio (limpieza, enriquecimiento) y finalmente cargados en el almacenamiento de destino.

ELT (Extract, Load, Transform): El modelo moderno predominante, posibilitado por el alto rendimiento de las bases de datos actuales y la nube. Los datos se extraen y se cargan directamente en el destino, y las transformaciones se realizan dentro del propio motor de base de datos utilizando lenguajes como SQL.

4. Interfaces de Programación de Aplicaciones (APIs)

Una API es un conjunto de reglas y protocolos que permite a diferentes aplicaciones de software comunicarse entre sí. En el contexto de los datos, son el mecanismo principal para la extracción estructurada de información desde sistemas externos o plataformas institucionales de forma segura y estandarizada.

5. Orquestación de Datos

Se refiere a la automatización, coordinación y monitorización de flujos de trabajo de datos complejos. Herramientas de orquestación, como Apache Airflow o Prefect, permiten programar la ejecución de pipelines, gestionar dependencias entre tareas, manejar errores y asegurar que los procesos se ejecuten en el orden correcto y en los tiempos definidos.

6. Almacenamiento Arquitectónico: Data Warehouse y Data Lake

Data Warehouse (Almacén de Datos): Un repositorio centralizado diseñado para almacenar datos estructurados y procesados, optimizado para consultas rápidas y análisis histórico.

Data Lake (Lago de Datos): Un repositorio que almacena grandes volúmenes de datos en su formato crudo y original (estructurados, semiestructurados o no estructurados) hasta que sean necesarios para su procesamiento.

7. Calidad y Gobierno de Datos

El gobierno de datos comprende las políticas y normativas que aseguran el uso correcto, la seguridad y la privacidad de la información. La calidad de datos implica procesos técnicos de validación para eliminar duplicados, manejar valores nulos y estandarizar formatos, garantizando que los sistemas de destino operen con información confiable.

IV. Trabajos Relacionados

La evolución de la ingeniería de datos ha motivado a diversas instituciones académicas y corporativas a modernizar sus infraestructuras tecnológicas, transitando hacia modelos escalables y seguros. A continuación, se presentan casos de estudio aplicados en ambos sectores.

La implementación de arquitecturas modernas de datos en instituciones de educación superior ha cobrado gran relevancia para centralizar operaciones y optimizar la gobernanza de la información. Un estudio reciente centrado en la Universidad de Trás-os-Montes y Alto Douro (UTAD) desarrolló una arquitectura de Inteligencia de Negocios (BI) basada en la nube. Este caso demostró que, mediante una correcta ingeniería de datos, la institución logró integrar múltiples fuentes fragmentadas, garantizando la seguridad de los registros académicos y el cumplimiento estricto de las normativas de privacidad institucionales (IEEE, 2024)

En el sector empresarial, la estandarización de tuberías de datos (*Data Pipelines*) y la migración hacia modelos ELT son el estándar para prevenir vulnerabilidades y reducir costos de mantenimiento. (Jadhav, 2025) analizó la arquitectura de una compañía global de *retail online*, destacando la implementación de un sistema de capas (bronce, plata y oro) para procesar datos extraídos desde diversas APIs. Esta estandarización no solo facilitó la limpieza de grandes volúmenes de datos en formato JSON, sino que también fortaleció la detección de anomalías y la trazabilidad de la información desde su origen hasta el modelo analítico.

Adicionalmente, la transición hacia el *Modern Data Stack* ha permitido a empresas de telecomunicaciones gestionar infraestructuras masivas. Un caso destacado es el de Spark New Zealand, corporación que, al migrar su arquitectura de datos hacia un modelo elástico en la nube con catálogos automatizados, logró gestionar un acceso seguro y auditado a cientos de bases de datos, mitigando cuellos de botella operativos y asegurando el control de accesos (Alation, 2025)

V. Herramientas y Tecnologías

La implementación de arquitecturas de datos modernas, escalables y seguras requiere de un ecosistema de herramientas especializadas, conocido comúnmente como *Modern Data Stack*. Este conjunto tecnológico permite gestionar el ciclo de vida del dato desde su origen hasta su disponibilidad para el consumo. A continuación, se detallan las plataformas y *frameworks* predominantes:

1. Lenguajes de Programación y Librerías Base

El desarrollo de tuberías de datos requiere lenguajes versátiles que permitan tanto la conexión segura a APIs como la manipulación de grandes volúmenes de información.

- **Python:** Es el lenguaje estándar de facto en la ingeniería de datos moderna. Destacan dos librerías para la manipulación de *DataFrames*:
 - **Pandas:** Ampliamente adoptada y madura, ideal para la limpieza y análisis de conjuntos de datos de tamaño moderado.
 - **Polars:** Una alternativa emergente escrita en Rust. *Comparativa:* A diferencia de Pandas, que opera en un solo hilo (*single-threaded*), Polars está diseñado para el procesamiento multihilo, ofreciendo un rendimiento significativamente superior en la ingesta y transformación de datos pesados.
- **SQL Avanzado:** Fundamental para las metodologías ELT, permitiendo realizar transformaciones complejas, uniones (*joins*) y funciones de ventana (*window functions*) directamente dentro de los motores de bases de datos.

2. Plataformas de Orquestación

La automatización y el monitoreo de los flujos de trabajo son esenciales para garantizar la disponibilidad y detectar fallos a tiempo.

- **Apache Airflow:** Plataforma de código abierto estándar en la industria. Utiliza Grafos Acíclicos Dirigidos (DAGs) escritos en Python para programar tareas. Es altamente robusta, pero presenta una curva de aprendizaje pronunciada y una infraestructura pesada.
- **Prefect:** Herramienta moderna de orquestación. *Comparativa:* Mientras que Airflow requiere estructurar rígidamente el código en DAGs, Prefect ofrece un enfoque más dinámico y "Pythónico", permitiendo convertir funciones de Python existentes en flujos de trabajo orquestados con menores configuraciones iniciales, facilitando así el manejo ágil de errores.

3. Frameworks de Transformación (ELT)

- **dbt (data build tool):** Es el estándar de la industria para ejecutar transformaciones de datos dentro del *Data Warehouse* utilizando sentencias SQL simples. Permite aplicar principios de ingeniería de software (como el control de versiones, pruebas unitarias y documentación automatizada) directamente a la lógica de negocio de los datos.

3. Procesamiento Distribuido y Arquitecturas Avanzadas

Para entornos institucionales que manejan volúmenes masivos de registros, las herramientas de nodo único son insuficientes.

- **Apache Spark (PySpark):** Motor unificado para el procesamiento de datos a gran escala, capaz de distribuir la carga de trabajo en clústeres de servidores.
- **Ecosistema Lakehouse:** Tecnologías de almacenamiento como Delta Lake o Apache Iceberg combinan la flexibilidad de un *Data Lake* con la rigurosidad transaccional (ACID) y la inmutabilidad de un *Data Warehouse* tradicional.
- **Kafka:** Plataforma de transmisión de eventos (*streaming*), utilizada cuando se requiere mover datos en tiempo real en lugar de procesamiento por lotes (*batch*).

5. Versionado y Observabilidad

- Además del uso transversal de Git para el control del código fuente, el *Modern Data Stack* incorpora herramientas de versionado de datos como DVC (Data Version Control) o lakeFS, que permiten mantener la trazabilidad exacta de los conjuntos de datos en un momento dado, mitigando riesgos de corrupción de la información.

VI. Tendencias y Futuro

La Ingeniería de Datos se encuentra en una etapa de madurez acelerada, impulsada por la adopción masiva de la Inteligencia Artificial y la necesidad crítica de proteger la información institucional. Al analizar la trayectoria tecnológica de la industria y la academia, se proyectan las siguientes tendencias fundamentales para los próximos años:

1. DevSecDataOps: Seguridad Integrada en las Tuberías (Shift-Left Security)

La seguridad y el gobierno de datos dejarán de ser auditorías posteriores para integrarse directamente en el código de las tuberías de extracción y carga. La tendencia apunta a la implementación de escaneos automatizados dentro de los pipelines que detecten y enmascaren dinámicamente Información Personal Identificable (PII) antes de que alcance el almacenamiento final. Esto previene fugas de datos (data breaches) desde el origen, estableciendo una postura de defensa proactiva frente a ciberamenazas emergentes.

2. Transición hacia Data Mesh (Malla de Datos)

Frente a los cuellos de botella generados por los Data Lakes monolíticos centralizados, las arquitecturas evolucionarán hacia el Data Mesh. Este paradigma descentralizado trata a los datos como un "producto" gestionado por dominios específicos (por ejemplo, el dominio académico o el dominio financiero de la universidad), distribuyendo la responsabilidad de la calidad y la estructura de los datos, pero bajo una gobernanza de seguridad global compartida.

3. Observabilidad Avanzada y Flujos Autoreparables (Self-Healing Pipelines)

El monitoreo tradicional de errores evolucionará hacia una observabilidad integral mediante inteligencia artificial (AIOps). Las plataformas de orquestación futuras no solo alertarán sobre un fallo en la ingesta de datos o una anomalía en los esquemas, sino que serán capaces de aplicar medidas correctivas automatizadas (como reintentos inteligentes o desvío de tráfico de datos corruptos) sin intervención humana inmediata, reduciendo drásticamente el tiempo de inactividad de los sistemas.

4. Procesamiento en Tiempo Real (Streaming Data) por Defecto

La latencia introducida por el procesamiento por lotes (*batch*) será reemplazada progresivamente por arquitecturas de transmisión de eventos en tiempo real (utilizando herramientas como Kafka o Apache Flink). Esto será indispensable para alimentar motores de analítica de seguridad en vivo y agentes de inteligencia artificial que requieren contexto institucional al instante para la toma de decisiones.

VII. Conclusiones

La investigación del estado del arte evidencia que la Ingeniería de Datos ha trascendido la simple extracción y carga de información para convertirse en la columna vertebral tecnológica y de seguridad de cualquier organización. Se concluye que la adopción de metodologías ELT, el uso de herramientas modernas de orquestación y la integración de seguridad desde el diseño estructural son imperativos técnicos para garantizar infraestructuras de datos escalables, inmutables y resilientes.

En el contexto del Prácticum dentro de la Dirección General de Tecnologías de la Información y Transformación Digital (DGTITD), estos hallazgos aterrizan directamente en el reto operativo de la línea de Ingeniería de Datos. La construcción de tuberías para la Universidad Técnica Particular de Loja exigirá no solo el dominio técnico de lenguajes como Python y SQL avanzado para la ingesta desde APIs, sino la implementación de una arquitectura que asegure la privacidad y gobernanza de los registros académicos y administrativos. El objetivo puntual radicará en desarrollar flujos de extracción y transformación que garanticen la limpieza y trazabilidad de la información, proveyendo bases de datos sólidas y seguras para que las áreas dependientes (Analítica, Inteligencia Artificial y Visualización) puedan operar con total confiabilidad sobre los activos digitales de la institución.

VIII. Referencias

Alation. (2025, Noviembre 3). *The Modern Data Stack Explained: What to Know in 2026*.

Retrieved from Alation Blog: <https://www.alation.com/blog/modern-data-stack-explained/>

IEEE. (2024, Noviembre 06). *Data Engineering Roadmap for Implementing Business Intelligence in Higher Education*. Retrieved from IEEE Xplore:

<https://ieeexplore.ieee.org/document/10740453>

Jadhav, A. (2025, Enero). *Standardization of system integrated data engineering architecture*.

Retrieved from International Journal of Computer Applications:

<https://www.ijcaonline.org/archives/volume186/number60/jadhav-2025-ijca-924363.pdf>