

De Silos a Inteligencia Estratégica: Arquitectura ETL y Data Warehouse para el Descubrimiento de Fuga de Talentos

Lucas Darío Jumbo Granda
Ciencias de la Computación
Universidad Técnica Particular de Loja
Loja, Ecuador

Abstract—Este documento detalla el diseño e implementación de un Data Warehouse y un conducto de datos (Pipeline ETL) automatizado para resolver la extrema fragmentación de los datos abiertos en el sector público ecuatoriano. Frente a la problemática de repositorios aislados, formatos incompatibles y datos anómalos (Dirty Data) provenientes del MINEDUC, el Banco Central, el INEC y la Superintendencia de Compañías, se estructuró una arquitectura escalable de tres capas sobre PostgreSQL. Mediante el uso de Python y el orquestador Prefect, se implementaron técnicas de procesamiento masivo diferido (Lazy Loading) para volcados robotizados (RPA), estandarización heurística y modelado dimensional (Star Schema). La prevención de productos cartesianos a través de Vistas SQL (Capa Gold) permitió el despliegue de tableros de Business Intelligence. El análisis visual evidenció una asimetría demográfico-corporativa tipificada como “Fuga de Talentos”, demostrando que la centralización gobernada de datos es el pilar fundamental para el diseño focalizado de políticas académicas y económicas.

Index Terms—Open Data, ETL, Data Warehouse, Data Cleansing, Star Schema, Python, Business Intelligence, Prefect, RPA.

I. INTRODUCCIÓN

La toma de decisiones basada en datos (Data-Driven) en el sector público ecuatoriano requiere información precisa, histórica y relacional. Sin embargo, los repositorios de datos abiertos operan en silos institucionales. Las metodologías modernas de ingeniería de datos proponen la creación de conductos automatizados (Pipelines) que consoliden estas fuentes en arquitecturas centralizadas, permitiendo descubrir correlaciones vitales entre indicadores macroeconómicos, educativos y demográficos.

II. PROBLEMÁTICA

La formulación de políticas públicas y la toma de decisiones estratégicas en Ecuador se ven severamente limitadas por la forma en que las instituciones gubernamentales publican su información. A pesar de la existencia de portales de datos abiertos, la integración analítica de estos registros presenta desafíos críticos:

- **Silos de Información y Desconexión Relacional:** Las bases de datos operan de forma aislada. No existe una infraestructura centralizada que permita cruzar, de manera nativa, indicadores del Banco Central con las métricas de empleo del INEC o el desempeño educativo del MINEDUC.

- **Carencia de Estandarización Técnica (Dirty Data):** Las fuentes primarias presentan formatos heterogéneos y anómalos. Se detectan delimitadores incompatibles en archivos CSV, codificaciones conflictivas (latin1 vs. UTF-8), y documentos Excel con metadatos no tabulares que impiden la lectura algorítmica.
- **Inconsistencias Estructurales y de Granularidad:** Los conjuntos carecen de llaves primarias homologadas. Se evidencian registros con identificadores nulos y asimetrías en la granularidad temporal (períodos irregulares) y geográfica (bases cantonales frente a provinciales).

Esta acumulación de deficiencias imposibilita el análisis automatizado, obligando a realizar intervenciones manuales altamente propensas a errores y retrasando el despliegue de inteligencia de negocios.

III. METODOLOGÍA Y STACK TECNOLÓGICO

Para superar estas barreras, se implementó un stack tecnológico híbrido enfocado en resiliencia, reproducibilidad y escalabilidad:

- **Framework de Transformación (Pandas/Python):** Encargado de la desestructuración de matrices, limpieza de diacríticos y fusiones vectorizadas de los archivos brutos.
- **Orquestación de Flujos (Prefect):** Utilizado para estructurar el pipeline en componentes lógicos (@task) dirigidos por un flujo maestro (@flow). Asegura la ejecución secuencial y el manejo de dependencias.
- **Capa de Persistencia (PostgreSQL):** Motor RDBMS elegido por su fuerte cumplimiento de restricciones de integridad (Constraints), desplegado mediante contenedores Docker.
- **Conectividad y Virtualización:** SQLAlchemy actuó como puente ORM para inyecciones masivas, mientras que la capa visual se delegó a Metabase.

IV. FASE DE PROCESAMIENTO Y LIMPIEZA (DATA CLEANSING)

El hito inicial fue la construcción de la “Capa Silver”. Se programaron algoritmos de limpieza específicos para mitigar las anomalías de cada institución:

A. *Procesamiento Masivo y Extracción Robotizada (RPA)*

Para los datos de la Superintendencia de Compañías, se dependió de un proceso RPA que generó un volcado SQL monolítico que superaba la capacidad de la memoria RAM (Out-Of-Memory) al intentar ser procesado convencionalmente. Se desarrolló un procesador iterativo (*Lazy Loading*) que fragmentó el archivo en lotes (*chunks*) de 50,000 registros, utilizando Expresiones Regulares para decodificar estructuras JSON complejas y liberando memoria de forma dinámica.

B. *Sanitización de Datos del INEC*

En el Censo 2022, la información cantonal no coincidía con la dimensión provincial requerida, por lo que se programó una función de agregación espacial (*groupby*) para consolidar la población ocupada mediante sumatorias geográficas y sectoriales.

C. *Estandarización de Métricas (MINEDUC y BCE)*

Los períodos lectivos se normalizaron mediante expresiones regulares para aislar el año absoluto. Simultáneamente, las matrices del Banco Central sufrieron un proceso de despivotación (*Unpivot*) para transformar columnas sectoriales en atributos categóricos, cumpliendo con la Primera Forma Normal (1NF).

V. ARQUITECTURA Y ESTABILIZACIÓN DEL DATA WAREHOUSE

Los datos saneados alimentaron un Modelo de Esquema en Estrella (*Star Schema*). Se definieron dimensiones transversales (*dim_tiempo* y *dim_geografia*) sobre las cuales pivotan masivas tablas de hechos: Empleo, Censo, Empresas, Bachilleres y Macroeconomía.

A. *Estabilización del Orquestador e Integridad Relacional*

Durante la fase de integración, se resolvieron deficiencias estructurales críticas:

- **Resolución de Dependencias Espaciales:** Se implementó la librería *pathlib* para garantizar que el orquestador localice las dependencias referenciando siempre la raíz absoluta del proyecto.
- **Integridad de Transacciones:** Se identificó un fallo de inserción originado por la ausencia de un identificador geográfico comodín (*id_geo = 0*) para registros de alcance “Nacional”. La reestructuración del flujo aseguró que las dimensiones sean pobladas como prerequisite absoluto previo a cualquier inyección de tablas de hechos.
- **Invocación Determinista:** Se encapsuló la lógica de extracción, permitiendo que Prefect asuma el control total de los reintentos y el manejo de excepciones.

VI. CONSTRUCCIÓN DE LA CAPA GOLD (VISTAS ANALÍTICAS)

Para habilitar la explotación de datos sin exponer la complejidad relacional al motor de Business Intelligence, se desarrolló una “Capa Gold” en PostgreSQL:

- **Prevención de Productos Cartesianos:** Al realizar cruces interinstitucionales (ej. MINEDUC y Supercias),

un JOIN convencional generaría duplicidad geométrica de filas. Se emplearon Expresiones de Tabla Comunes (CTE) para pre-agregar (*GROUP BY*) los totales provinciales de forma aislada antes de su fusión.

- **Métricas de Negocio Calculadas:** El motor de base de datos resuelve operaciones analíticas como el Ratio Laboral, protegiendo las sentencias con la cláusula *NULLIF* para prevenir errores de división por cero.

VII. DESPLIEGUE ANALÍTICO (BUSINESS INTELLIGENCE)

La Capa Gold fue virtualizada en Metabase, estructurando un Dashboard Estratégico en tres fases analíticas:

A. *Fase 1: Contexto Macroeconómico*

Se visualiza el PIB per cápita (tendencia) en contraste con su variación porcentual (barras). Este cruce establece el marco de referencia, identificando si la contracción corporativa responde a una recesión sistémica del país.

B. *Fase 2: Concentración Empresarial y Empleo*

Expone una dicotomía estructural nacional. Se demuestra un oligopolio geográfico corporativo fuertemente concentrado en Guayas y Pichincha, mientras que la Tasa de Desempleo Oficial se mantiene plana, visibilizando los profundos índices reales de subempleo e informalidad.

C. *Fase 3: Brecha Laboral y Fuga de Talentos*

Constituye el hallazgo de mayor valor estratégico. Mediante un análisis de dispersión, se cruzó el volumen de bachilleres frente a la densidad de empresas activas. El modelo evidenció un agrupamiento crítico de provincias que gradúan miles de estudiantes pero poseen un tejido empresarial marginal. Este fenómeno, tipificado como “Fuga de Talentos”, proporciona inteligencia táctica a la universidad para dirigir estrategias de captación y formación a distancia hacia sectores históricamente desatendidos.

VIII. CONCLUSIONES

La implementación de este Pipeline ETL evidencia que es técnica y logísticamente posible transformar volcados robotizados complejos y repositorios fragmentados en activos analíticos de alto valor. Al establecer un conducto de datos determinista orquestado mediante flujos a demanda, y relegar el procesamiento pesado al motor relacional a través de la Capa Gold, se erradica la dependencia de reportes estáticos. El descubrimiento de la “Fuga de Talentos” demuestra fehacientemente que la ingeniería de datos escalable es el cimiento indispensable para la formulación precisa de políticas académicas y económicas en el Ecuador.