

Estado del Arte e Implementación Técnica: Pipeline ETL y Data Warehouse para Indicadores Gubernamentales

Lucas Darío Jumbo Granda
Ciencias de la Computación
Universidad Técnica Particular de Loja
Loja, Ecuador

Abstract—...

Index Terms—Open Data, ETL, Data Warehouse, Data Cleansing, Star Schema, Python.

I. INTRODUCCIÓN

La toma de decisiones basada en datos (Data-Driven) en el sector público ecuatoriano requiere información precisa, histórica y relacional. Sin embargo, los repositorios de datos abiertos operan en silos institucionales. Las metodologías modernas de ingeniería de datos proponen la creación de conductos automatizados (Pipelines) que consoliden estas fuentes en arquitecturas centralizadas, permitiendo descubrir correlaciones entre indicadores macroeconómicos, educativos y demográficos.

II. PROBLEMÁTICA

La formulación de políticas públicas y la toma de decisiones estratégicas en Ecuador se ven limitadas por la forma en que las instituciones gubernamentales publican su información. A pesar de la existencia de portales de datos abiertos, la integración analítica de estos registros presenta los siguientes desafíos críticos:

- **Silos de Información y Desconexión Relacional:** Las bases de datos operan de forma aislada. No existe una infraestructura centralizada que permita cruzar, de manera nativa, indicadores macroeconómicos del Banco Central con las métricas de empleo del INEC o el desempeño educativo del MINEDUC.
- **Carencia de Estandarización Técnica (Dirty Data):** Las fuentes primarias presentan formatos heterogéneos y anómalos. Se detectan delimitadores incompatibles en archivos CSV, codificaciones conflictivas (latin1 vs. UTF-8), y documentos Excel con metadatos no tabulares (logotipos institucionales, celdas combinadas) que impiden la lectura algorítmica secuencial.
- **Inconsistencias Estructurales y de Granularidad:** Los conjuntos de datos carecen de llaves primarias y foráneas homologadas. Se evidencian registros con identificadores nulos (empresas en liquidación sin RUC), así como asimetrías en la granularidad temporal (períodos compuestos como “2009-2010 Fin”) y geográfica (bases de datos a nivel cantonal frente a otras a nivel provincial).

Esta acumulación de deficiencias imposibilita el análisis automatizado de inteligencia de negocios, obligando a realizar intervenciones manuales altamente propensas a errores antes de poder extraer valor real de los datos gubernamentales.

III. METODOLOGÍA Y STACK TECNOLÓGICO

Para el desarrollo de la solución, se implementó un stack tecnológico híbrido enfocado en resiliencia y tolerancia a fallos:

- **Framework de Transformación (Pandas):** Encargado de la desestructuración de matrices complejas, limpieza de diacríticos y fusiones (Merges) vectorizadas.
- **Capa de Persistencia (PostgreSQL):** Motor RDBMS elegido por su fuerte cumplimiento de restricciones de integridad (Constraints), previniendo la inyección de datos huérfanos.
- **Conectividad (SQLAlchemy):** Actúa como puente ORM para ejecutar inserciones masivas (*bulk inserts*) de forma transaccional.

IV. FASE DE PROCESAMIENTO Y LIMPIEZA (DATA CLEANSING)

El hito principal alcanzado es la construcción de la “Capa Silver”. Se diseñaron algoritmos de limpieza específicos para cada anomalía institucional:

A. Sanitización de Datos del INEC

Los archivos de la ENEMDU presentaban delimitadores no estándar (punto y coma). Se reprogramó el parser para aislar estas matrices. En el Censo 2022, la información cantonal no coincidía con la dimensión provincial de la base de datos, por lo que se desarrolló una función de agrupación espacial (*groupby*) para consolidar la población ocupada mediante sumatorias por provincia y sector industrial.

B. Resolución de Anomalías en Sector Empresarial

La Superintendencia de Compañías publicó sus datos con matrices corruptas y cadenas sin escapar. Se configuró el parser en C de Pandas en modo defensivo (*on_bad_lines='skip'*) para descartar ruido sintáctico. Adicionalmente, se eliminó la explosión cartesiana aplicando deduplicación en los identificadores de la dimensión temporal,

cruzando los balances contables exclusivamente con el cierre del año fiscal. Se aplicaron reglas de negocio estrictas para descartar empresas en liquidación sin registro RUC.

C. Estandarización de Métricas (MINEDUC y BCE)

Los períodos lectivos (ej. “2009-2010 Fin”) se normalizaron mediante expresiones regulares (Regex) para extraer el año absoluto. Por su parte, las matrices anchas del Banco Central (VAB) sufrieron un proceso de despivotación (Unpivot/Melt) para transformar columnas sectoriales en atributos categóricos, cumpliendo con la Primera Forma Normal (1NF).

V. ARQUITECTURA DEL DATA WAREHOUSE

Los datos saneados fueron inyectados en un Modelo de Esquema en Estrella. Se definieron dos dimensiones catalogadas (*dim_tiempo* y *dim_geografia*) como el centro del contexto, sobre las cuales pivotan las siguientes tablas de hechos (*Fact Tables*):

TABLE I
REGISTROS CONSOLIDADOS EN LA CAPA SILVER

Tabla de Hechos (Métrica)	Granularidad	Volumen
fact_empleo_enemdu	Mensual / Area	~23,800
fact_censo_actividad	Anual / Prov	~93,100
fact_empresas_supercias	Anual / Prov	~1,331,200
fact_bachilleres_mineduc	Anual / Prov	~294,200
fact_macro_anual (BCE)	Anual / Prov	Consolidado