

Estado del Arte e Implementacion Tecnica: Pipeline ETL y Data Warehouse para Indicadores Gubernamentales

Lucas Dario Jumbo Granda
Ciencias de la Computacion
Universidad Tecnica Particular de Loja
Loja, Ecuador

Abstract— ...

Index Terms—Open Data, ETL, Data Warehouse, Data Cleansing, Star Schema, Python.

I. INTRODUCCION

La toma de decisiones basada en datos (Data-Driven) en el sector publico ecuatoriano requiere informacion precisa, historica y relacional. Sin embargo, los repositorios de datos abiertos operan en silos institucionales. Las metodologias modernas de ingenieria de datos proponen la creacion de conductos automatizados (Pipelines) que consoliden estas fuentes en arquitecturas centralizadas, permitiendo descubrir correlaciones entre indicadores macroeconomicos, educativos y demograficos.

II. PROBLEMÁTICA

En la literatura reciente sobre integracion de datos abiertos (Open Data), el mayor cuello de botella es la fase de preparacion de datos. Los registros administrativos suelen sufrir de “Dirty Data” (datos sucios). Las soluciones contemporaneas emplean procesamiento en memoria (In-Memory Processing) mediante bibliotecas de manipulacion de tensores y DataFrames (como Apache Arrow o Pandas), desplazando las transformaciones pesadas fuera del motor de base de datos para reducir el costo transaccional (Extract-Transform-Load clasico). Ademas, el modelado dimensional propuesto por Ralph Kimball sigue siendo el estandar de la industria para optimizar cargas de trabajo analiticas (OLAP).

III. METODOLOGIA Y STACK TECNOLÓGICO

Para el desarrollo de la solucion, se implemento un stack tecnologico hibrido enfocado en resiliencia y tolerancia a fallos:

- **Framework de Transformacion (Pandas):** Encargado de la desestructuracion de matrices complejas, limpieza de diacriticos y fusiones (Merges) vectorizadas.
- **Capa de Persistencia (PostgreSQL):** Motor RDBMS elegido por su fuerte cumplimiento de restricciones de integridad (Constraints), previniendo la inyeccion de datos huérfanos.
- **Conectividad (SQLAlchemy):** Actua como puente ORM para ejecutar inserciones masivas (*bulk inserts*) de forma transaccional.

IV. FASE DE PROCESAMIENTO Y LIMPIEZA (DATA CLEANSING)

El hito principal alcanzado es la construccion de la “Capa Silver”. Se disenaron algoritmos de limpieza especificos para cada anomalia institucional:

A. Sanitizacion de Datos del INEC

Los archivos de la ENEMDU presentaban delimitadores no estandar (punto y coma). Se reprogramo el parser para aislar estas matrices. En el Censo 2022, la informacion cantonal no coincidia con la dimension provincial de la base de datos, por lo que se desarrollo una funcion de agrupacion espacial (*groupby*) para consolidar la poblacion ocupada mediante sumatorias por provincia y sector industrial.

B. Resolucion de Anomalias en Sector Empresarial

La Superintendencia de Companias publico sus datos con matrices corruptas y cadenas sin escapar. Se configuro el parser en C de Pandas en modo defensivo (*on_bad_lines='skip'*) para descartar ruido sintactico. Adicionalmente, se elimino la explosion cartesiana aplicando deduplicacion en los identificadores de la dimension temporal, cruzando los balances contables exclusivamente con el cierre del año fiscal. Se aplicaron reglas de negocio estrictas para descartar empresas en liquidacion sin registro RUC.

C. Estandarizacion de Metricas (MINEDUC y BCE)

Los periodos lectivos (ej. “2009-2010 Fin”) se normalizaron mediante expresiones regulares (Regex) para extraer el año absoluto. Por su parte, las matrices anchas del Banco Central (VAB) sufrieron un proceso de despivotacion (Unpivot/Melt) para transformar columnas sectoriales en atributos categoricos, cumpliendo con la Primera Forma Normal (1NF).

V. ARQUITECTURA DEL DATA WAREHOUSE

Los datos saneados fueron inyectados en un Modelo de Esquema en Estrella. Se definieron dos dimensiones catalogadas (*dim_tiempo* y *dim_geografia*) como el centro del contexto, sobre las cuales pivotan las siguientes tablas de hechos (*Fact Tables*):

TABLE I
REGISTROS CONSOLIDADOS EN LA CAPA SILVER

Tabla de Hechos (Métrica)	Granularidad	Volumen
fact_empleo_enemdu	Mensual / Area	~23,800
fact_censo_actividad	Anual / Prov	~93,100
fact_empresas_supercias	Anual / Prov	~1,331,200
fact_bachilleres_mineduc	Anual / Prov	~294,200
fact_macro_anual (BCE)	Anual / Prov	Consolidado