

Pipeline ETL y Análisis Analítico del Registro Administrativo del Mineduc (2009-2024)

Lucas Dario Jumbo Granda
Universidad Técnica Particular de Loja
Loja, Ecuador

Resumen—Este reporte presenta el desarrollo de un pipeline ETL optimizado para depurar el Registro Administrativo Histórico del Mineduc. De un esquema original de 104 variables y 290,310 filas, se seleccionaron 16 atributos críticos procesados con Pandas y persistidos en una base de datos SQLite. Finalmente, se conectó un cuadro de mando en Power BI para analizar la concentración de la matrícula, la oferta educativa en Loja y la evolución temporal de las instituciones.

I. INTRODUCCIÓN

El análisis de datos públicos masivos exige procesos de ingeniería que garanticen la calidad de la información. Las fuentes crudas del Ministerio de Educación (AMIE) presentan problemas de redundancia y dispersión estructural. Este reto implementa un pipeline automatizado en Python para centralizar, limpiar y visualizar estos históricos de forma eficiente.

II. ANÁLISIS EXPLORATORIO (EDA) Y ETL

La exploración inicial se ejecutó en `1_exploracion.ipynb`, detectando una matriz de 290,310 filas y 104 columnas con gran cantidad de nulos en variables administrativas secundarias. Se aplicó una reducción de dimensionalidad aislando 16 columnas estratégicas.

El proceso de transformación (`2_limpieza_y_carga.ipynb`) ejecutó las siguientes reglas de negocio:

- **Estandarización:** Mapeo de nombres para compatibilidad SQL.
- **Tratamiento de nulos y duplicados:** Sustitución de valores vacíos en métricas por 0 (`.fillna(0)`) y eliminación de 2 registros duplicados.
- **Consistencia Matemática:** Corrección de errores aritméticos en la fuente mediante la sumatoria vectorial por género:

$$\text{total_estudiantes} = \text{estudiantes_f} + \text{estudiantes_m} \quad (1)$$

III. PERSISTENCIA Y ALMACENAMIENTO

Los 290,308 registros limpios se exportaron mediante SQLAlchemy a una base de datos relacional local SQLite (`amie_mineduc.db`). Se diseñó una arquitectura de tabla única denormalizada (`instituciones`) con el fin de maximizar la velocidad de lectura.

IV. VISUALIZACIÓN Y ANÁLISIS DE RESULTADOS

El modelo de datos se acopló a Power BI Desktop configurando `total_estudiantes` como métrica agregada (Σ) y `cod_amie` como recuento distintivo.

IV-A. Top 5 Provincias por Matrícula

En el ciclo “2022-2023 Inicio”, las provincias de Guayas (~1.09M alumnos) y Pichincha (~680K) concentran la mayor demanda del sistema educativo nacional, evidenciando una fuerte centralización demográfica.

IV-B. Infraestructura Educativa en Loja

Al aislar la provincia de Loja para el periodo más reciente, se descubrió una asimetría estructural: el área urbana mantiene un equilibrio relativo (120 escuelas fiscales vs. 95 particulares), mientras que el área rural expone una dependencia absoluta del sector público con 647 escuelas Fiscales frente a solo 1 Particular.

IV-C. Tendencia Histórica (2015-2023)

El análisis cronológico capturó un decrecimiento negativo continuo en el número de instituciones activas a nivel nacional (cayendo de ~16.2K a ~12.4K). Esta tendencia responde a la política pública de fusión de escuelas unidocentes hacia Unidades Educativas del Milenio integrales.

V. CONCLUSIONES

El pipeline ETL desarrollado optimizó el procesamiento en RAM. La base de datos denormalizada en SQLite aseguró una transferencia ágil y sin latencia hacia Power BI. Finalmente, los visuales arrojaron métricas clave sobre la realidad educativa rural y urbana, cumpliendo rigurosamente con los estándares de ingeniería de la materia.

REFERENCIAS

- [1] Ministerio de Educación del Ecuador, “Registro Administrativo Histórico AMIE”, 2024.